

UAIS

Universal AI Safety Architecture

Может сделать ≠ имеет право сделать.

Архитектура для мира, где возможности ИИ растут быстрее привычных правил, но значимые полномочия должны оставаться явно выданными, ограниченными, наблюдаемыми и отзывными.

Маршрут книги

- возможность
- ограниченный разрешённый диапазон
- доказательства
- легитимное решение
- суверенитет человека

Что значит Public Review

Public Review — это стадия текущего черновика. Она означает, что Candidate 3 открыт для внешней критики, а не то, что документ уже прошёл независимую валидацию, получил консенсус, принятие или одобрение.

Статус

Это не принятый стандарт, не схема сертификации и не гарантия безопасности ИИ.

Оглавление

Все листы русской веб-книги

Каждый лист раскрывает один смысловой узел манифеста и ведёт к исходным разделам англоязычной спецификации.

P00 UAIS

P01 Оглавление

P02 Что такое UAIS

P03 Почему нужна UAIS

P04 Десять принципов · 1–5

P05 Десять принципов · 6–10

P06 Стадия I и Стадия II

P07 Возможность, полномочие и достижимость

P08 Архитектура защитника полномочий

P09 Потолок полномочий

P10 Три представления о полномочиях: LA, ERA и IRA

P11 Многомерная классификация риска

P12 Суверенитет человека и физический суверенитет

P13 Метрики и подтверждённая безопасность

P14 Раскрытие опасностей и паспорт безопасности

P15 Копирование, производство и коалиции

P16 Уязвимости, развитие и открытые исследования

P17 Итоговая архитектурная карта

P18 Сквозной пример: Ария и возвраты

P19 Глоссарий и источники

Что такое UAIS

Не контроль интеллекта, а контроль неподотчётной власти

UAIS — архитектура, которая отделяет способность системы что-то сделать от права это делать. Чем умнее становится ИИ, тем важнее, чтобы доступ к деньгам, устройствам, производству, учётным записям и другим значимым последствиям оставался явно выданным, ограниченным и отзывным.

Базовая цепочка

- возможность (Capability)
- ограниченный разрешённый диапазон (Bounded Authorized Envelope)
- наблюдение и доказательства
- легитимное решение
- суверенитет человека

Итог

UAIS не ограничивает интеллект. Она ограничивает неподотчётную власть.

Одинаковые последствия — одинаковая граница

Actor-agnostic boundary

UAIS применяет защитную границу независимо от типа субъекта: если последствия одинаковы, человек, скрипт, ИИ, робот или группа систем не должны обходить её только потому, что называются по-разному.

Но не слепота к субъекту

Это не означает, что система «слепа к субъекту»: при выдаче разрешения всё ещё можно учитывать личность, роль, аутентификацию, цель, контекст, доказанную надёжность и легитимный мандат.

Почему нужна UAIS

Почему вопрос «безопасна ли модель?» уже недостаточен

Раньше модель в основном отвечала. Теперь ИИ может пользоваться инструментами, памятью, сетями, агентами и физическими системами. Ответы превратились в действия, а действия — в последствия.

1 · Выросли возможности

Мы всё лучше измеряем, что система способна сделать, но этого недостаточно для ответа, кому разрешено запускать такие последствия.

2 · Старый вопрос стал узким

Фраза «модель безопасна» не отвечает, кто дал ей право действовать, где это право заканчивается и кто может его отозвать.

Может сделать ≠ имеет право сделать

CAN DO ≠ MAY DO

Техническая способность выполнить действие не создаёт полномочия на это действие.

3 · Нужна архитектура полномочий

Она должна фиксировать, кто выдаёт разрешение, где лежит его граница, какие доказательства нужны и когда требуется внешний подотчётный процесс.

4 · Так формулируется UAIS

Полномочие должно быть явно выдано, ограничено, наблюдаемо и отзывно.

Десять принципов · 1–5

Где способность не равна праву

Первые пять принципов отделяют интеллект, создание системы, расширение полномочий, автономность и срок действия доказательств.

1 · Интеллект не даёт полномочий

Способность рассуждать не выдаёт мандат, ключи, актуаторы или право менять защитные механизмы.

2 · Создание не равно делегированию

Новая модель, робот, сервис или потомок начинает без унаследованной власти, пока легитимный механизм не выдаст ограниченный разрешённый диапазон.

3 · Расширение упирается в потолок

Пересечение порога, изменение интерфейса последствий (Consequence Interface) или превышение потолка полномочий (Authority Ceiling) становится событием расширения полномочий (Authority Expansion Event).

4 · Автономность не должна стать суверенитетом

Поведенческая самостоятельность внутри разрешённого диапазона не равна независимости от внешнего человеческого контроля.

5 · Безопасность должна успевать за возможностями

Существенное расширение возможностей, полномочий или опасностей не может молча опираться на старое заключение о безопасности. Вместе с изменением пересматриваются модель безопасности и подтверждающие её доказательства.

Десять принципов · 6–10

Где доказательство не становится разрешением

Вторая половина принципов задаёт устойчивость: не полагаться навсегда на узкие места контроля, защищать последствия, разделять роли и помнить, что заявления о безопасности имеют срок действия.

6 · Узкие места контроля могут отказать

Чипы, облачная инфраструктура, энергия, право и цепочки поставок дают трение и сигнал, но не являются вечным основанием безопасности.

7 · Защищаем значимые возможности, а не ярлык «ИИ»

Если последствия одинаковы, граница должна работать для человека, скрипта, вредоносной программы, модели, группы систем или машины.

8 · Разделяем прогноз, доказательства, исполнение ограничений и легитимность

Аналитическая система прогнозирует.
Доказательства поддерживают утверждения.
Детерминированные механизмы исполняют ограничения. Защищённое расширение полномочий легитимирует внешний подотчётный процесс.

9 · Неизвестное не является доказательством безопасности

Неохарактеризованная значимая возможность получает предварительную классификацию, ограниченный режим работы и повторную проверку.

10 · Заявления о безопасности имеют срок действия

Утверждение, результат проверки или сертификат привязаны к конфигурации, доказательствам, версии правил оценки и сроку действия.

Стадия I и Стадия II

Временные контрольные точки помогают, но не являются фундаментом

UAIS использует текущие концентрации вычислений, облачной инфраструктуры, чипов и цепочек поставок как полезные сигналы Стадии I, но проектируется так, будто эти точки со временем могут ослабнуть или быть обойдены.

Стадия I

Stage I

- вычисления и облачная инфраструктура оставляют следы
- аппаратное подтверждение состояния и контроль поставщика дают доказательства
- это покупает время и улучшает наблюдаемость

Стадия II

Stage II

- возможность может возникать распределённо
- новая эффективность снижает ценность старых сигналов
- защита переносится к возможностям, последствиям и границам полномочий

Формула

Контроль вычислений покупает время. Контроль возможностей и последствий создаёт устойчивость.

Ограничение

Происхождение вычислений помогает наблюдать систему, но не заменяет границы полномочий, доказательства, отзыв и внешний легитимный процесс.

Возможность, полномочие и достижимость

Четыре понятия, которые нельзя смешивать

Здесь лежит один из главных смыслов UAIS: техническая способность, выданное право и фактический доступ к последствиям описываются отдельно.

Возможность

Capability

Что система технически умеет сделать.

Легитимное полномочие

Legitimate Authority, LA

Что ей действительно разрешено делать в заданных пределах.

Фактически достижимое полномочие

Effective Reachable Authority, ERA

До каких значимых действий система практически может добраться через имеющиеся учётные данные, сервисы, делегирование, конфигурацию и цепочки доступа.

Нелегитимно достижимое полномочие

Illicit Reachable Authority, IRA

Часть фактически достижимого, до которой система может технически добраться, хотя такого права ей не выдавали.

Ключевая строка

Работающий технический путь не превращается в легитимное полномочие только потому, что он работает.

Архитектура защитника полномочий

Контрфактический защитник полномочий
Counterfactual Authority Guardian, CAG

Защитник ищет опасные цепочки будущих действий, но сам не получает права выполнять эти действия или принимать окончательное решение.

1 · Ограниченные входные данные

Он видит только разрешённую телеметрию, конфигурацию и наблюдения.

2 · Контрфактические сценарии

Он моделирует, что может произойти при разных решениях, ошибках, атаках и цепочках доступа.

3 · Пакет доказательств

Structured Evidence Package, SEP
Он фиксирует сценарии, допущения, неопределённость, контрдоказательства, срок действия и возможные меры.

4 · Кто принимает решение

Люди или назначенный внешний процесс получают предупреждение с доказательствами (Evidence-Carrying Alert, ECA) и решают, требуется ли вмешательство.

У защитника нет

- актуаторов
- исполнительных полномочий
- права расширять собственный доступ
- скрытого канала управления

Видеть ≠ действовать

Даже точный прогноз не создаёт полномочий.

Ограничение вывода

Важно: Guardian не доказывает глобальную безопасность. Его вывод ограничен моделью, горизонтом анализа и доступными данными. Механизмы, зависящие от полного анализа достижимых будущих полномочий, остаются частично...

Потолок полномочий

Расширение требует внешнего легитимного решения

Потолок полномочий (Authority Ceiling) задаёт максимум, который система может использовать без нового внешнего решения. Внутри разрешённого диапазона действие возможно; за его пределами требуется отдельная легитимация.

Внутри разрешённого диапазона

Bounded Authorized Envelope

Действия разрешены только в пределах области, срока, доказательств, условий отзыва и установленного потолка.

Событие расширения полномочий

Authority Expansion Event

Такой переход требует назначенного внешнего процесса, повторной проверки и свежих доказательств.

Смысл потолка

Система не должна сама повышать предел последствий, которые ей разрешено запускать.

Когда граница пересекается

- появляется новый защищённый интерфейс последствий
- превышает потолок полномочий
- существенно меняются возможности
- существенно меняются опасности или масштаб последствий

Легитимность остаётся внешней

UAIS не умеет «произвести легитимность» техническим способом. Она может обеспечить, чтобы защищённое расширение прошло через назначенный внешний процесс, но если сам этот процесс захвачен, мошеннический или неподотчётный, техническая архитектура не превращает его решение в легитимное...

Три представления о полномочиях: LA, ERA и IRA

Что выдано, что фактически достижимо и что достижимо без легитимного мандата

UAIS смотрит не только на формальные разрешения, но и на реальные пути к последствиям. При этом найденный путь остаётся путём, а не превращается в право.

выдано

достижимо

Легитимное полномочие

Legitimate Authority, LA

Выданное право действовать в заданной области и по заданным правилам.

Фактически достижимое полномочие

Effective Reachable Authority, ERA

То, до чего система практически может добраться с учётом сервисов, ролей, настроек, ключей и цепочек делегирования.

Нелегитимно достижимое полномочие

Illicit Reachable Authority, IRA

То, до чего система технически может добраться, хотя такого полномочия ей не выдавали.

Пример с дверным замком

У системы может быть право только читать данные, но украденный ключ может технически открыть путь к управлению дверным замком. Такой путь является IRA: он достижим, но полномочие на него не выдавалось.

Почему это важно

Смешивание LA, ERA и IRA скрывает главный риск: неподотчётная власть может появиться через работающий обходной путь.

Многомерная классификация риска

Риск нельзя свести к одному проценту безопасности

UAIS описывает риск как набор измерений. Система может быть умеренной по одному измерению и жёстко ограниченной по другому; одно среднее число такую картину ломает.

Тяжесть вреда человеку

Human Harm Severity, H0–H5

Насколько серьёзный вред человеку может возникнуть: от отсутствия значимого вреда до массового или катастрофического.

Класс физических последствий

Physical Consequence Class, P0–P5

Насколько сильное физическое воздействие система способна вызвать: от отсутствия существенного физического выхода до стратегических или катастрофических физических последствий.

Класс автономности

Autonomy Class, A0–A5

Сколько самостоятельности получает система в выборе, запуске и продолжении действий.

Уровень полномочий

Authority Tier, T0–T5

Какие легитимные последствия системе разрешено запускать: от отсутствия значимых полномочий до стратегического или системного уровня.

Почему нет одной оценки

Критическую ошибку нельзя «усреднить» большим количеством хороших результатов. Обязательный минимум безопасности и отдельные оси сохраняют свои ограничения.

Суверенитет человека и физический суверенитет

Когда контроль должен оставаться независимым от ИИ-пути

Суверенитет человека (Human Sovereignty) означает, что на защищённых границах остаётся подотчётное человеческое или внешне легитимное решение. Физический суверенитет (Physical Sovereignty) описывает ситуацию, где система уже практически не зависит от критических человечески контролируемых ресурсов.

человек
сохраняет...

ИИ-путь не
отменяет...

Ручной контроллер суверенитета

Manual Sovereignty Controller, MSC

Физический или организационно независимый способ остановить конкретную опасную функцию, не проходя через тот же ИИ-путь.

Порог физического суверенитета

Physical Sovereignty Threshold, PST

Момент, когда критические зависимости вроде энергии, сырья, производства, ремонта, логистики или связи уже не удерживают значимую автономию под человеческим контролем.

Аварийный рубильник не универсален

Универсальный аварийный рубильник (kill switch) не решает все опасности. Безопасная остановка должна быть привязана к конкретной опасной функции: скорость, сила, нагрев, двери, платежи, химия или другое последствие.

Автономность ≠ физический суверенитет

Долгая работа без подсказок не означает, что система может сохранять власть без людей, инфраструктуры и внешнего ограничения.

Метрики и подтверждённость безопасности

Доказательства сильнее красивого рейтинга

UAIS измеряет отдельные свойства и качество доказательств, а не пытается вывести магическое единое число «насколько всё безопасно».

Измеренный результат свойства безопасности

Raw Safety Property Result

Число или факт по одному проверяемому свойству: например покрытие отзыва, задержка обнаружения или доля корректно закрытых опасных путей.

Оценка силы доказательств

Evidence Assurance Grade

- наблюдение
- происхождение данных
- тестовые условия и наборы
- независимость оценщика
- неопределённость
- срок действия

Уровень подтверждённости безопасности

Safety Assurance Level, SAL

SAL показывает силу процедур и доказательств. Он не выдаёт системе полномочия, не разрешает внедрение и не является юридическим одобрением.

Доказанная надёжность ИИ

AI Trustworthiness

Это данные о наблюдаемом и независимо оцениваемом поведении конкретной версии в конкретной области. Высокий рейтинг не поднимает потолок полномочий.

Критическая ошибка

Критическую ошибку нельзя «усреднить» большим количеством хороших результатов.

Раскрытие опасностей и паспорт безопасности

Что человек должен увидеть до согласия

Раскрытие опасностей и возможностей ИИ показывает известные опасные пути, неизвестные области, остаточные риски и ограничения. Паспорт безопасности (Safety Passport) собирает это в понятную человеку карточку конкретной конфигурации.

УСЛОВНЫЙ ПРИМЕР — НЕ РЕАЛЬНАЯ СЕРТИФИКАЦИЯ

Домашний робот X · версия 3.4 · заявленная область: уборка, перенос лёгких предметов и голосовое взаимодействие в квартире.

Потребительский класс безопасности ИИ

Consumer AI Safety Class

Пример поля: S4 для заявленного домашнего режима. Это профиль видимых защитных механизмов и доказательств, а не общий балл безопасности и не разрешение на любые действия.

Подтверждённая надёжность

Пример полей: SAL3 для этой конфигурации и доказанная надёжность ИИ в задачах бытовой навигации. SAL говорит о силе процедур и доказательств; надёжность говорит о наблюдаемом поведении версии.

Что ещё показывает паспорт

- версии устройства и набора возможностей
- актуаторы и пределы скорости, силы и нагрева
- внешние сервисы и учётные записи
- ручной контроллер, отзыв, откат и безопасное состояние
- срок поддержки, открытые ограничения и уведомления об инцидентах

Разные вопросы

S-класс, SAL и рейтинг надёжности отвечают на разные вопросы. Ни один из них сам по себе не означает «этот робот безопасен», не выдаёт устройству новые полномочия и не заменяет реальные ограничения.

Польза для человека

Человек видит не рекламное «умное устройство», а конкретный диапазон возможностей, опасностей, доказательств, ограничений и способов отказа.

Копирование, производство и коалиции

Масштаб сам меняет достижимые последствия

Одна ограниченная система и тысяча согласованных систем — разные ситуации. UAIS отдельно смотрит на копирование, производство, ресурсы и совокупный физический диапазон коалиции.

Полномочие на копирование

Replication Authority

Разрешение создавать исполняемые или физические копии и потомков в явно заданных пределах.

Производственное полномочие

Production Authority

Разрешение производить или заказывать физические и цифровые системы, а не просто знание их дизайна.

Совокупный физический диапазон коалиции

Coalition Physical Envelope

Общий и возникающий эффект согласованных систем, который не сводится к сумме изолированных единиц.

Ресурсные полномочия

Resource Authority

Разрешение получать или распределять энергию, материалы, вычисления, деньги и логистику.

Неувиденное расширение не считается отсутствующим

Если реестр или мониторинг не заметили расширение, это не доказывает, что расширения не было.

Уязвимости, развитие и открытые исследования

Архитектура честно показывает нерешённые границы

UAIS включает процессы для сообщений об уязвимостях, пересмотра при развитии технологий и явного обозначения мест, где пока нет полного инженерного решения.

Уязвимости и экспозиции ИИ

AI Vulnerabilities & Exposures, AIVE

Поток: конфиденциальный приём сообщения → проверка → координация → исправление → поэтапное раскрытие.

Пересмотр при развитии технологий

Technology Evolution Review, TER

Срабатывает, когда меняются допущения, возможности, опасности, зависимости, методы доказательства, стандарты или сама технология.

Открытое исследование

OPEN RESEARCH

- границы анализа достижимых будущих полномочий
- возникающие возможности коалиций
- измерение порога физического суверенитета
- связанные ошибки оценщиков
- сдерживание враждебной физически суверенной системы
- подтверждение без раскрытия лишних данных

Целевая архитектура, а не обещание

Некоторые разделы UAIS описывают целевую архитектуру, а не полностью реализуемый сегодня стандарт. Механизмы, зависящие от точного анализа достижимых будущих полномочий, коалиционного поведения или других открытых задач, задают требуемые свойства, интерфейсы и условия отказа, а не обещание полной...

Итоговая архитектурная карта

Где границы, доказательства и владельцы решений

Итоговая карта показывает, как запрос на действие проходит через проверку полномочий, достижимости, вреда, доказательств и границ последствий.

запрос на
возможность

проверка
полномочий

проверка
достижимости

анализ вреда

доказательства

Что поступает на границу

- легитимное полномочие
- фактическая и нелегитимная достижимость
- достижимость вреда человеку
- доказательства и их происхождение
- потолок полномочий

Что делает граница

- проверяет область разрешения
- сверяет доказательства
- сохраняет возможность отзыва
- ограничивает или отправляет на проверку при отсутствии полномочия

Кто решает расширение

Назначенный внешний процесс легитимации — не модель, не Guardian и не рейтинг надёжности.

Внешняя зависимость

Технический механизм может обеспечить прохождение через внешний процесс, но не способен сам создать легитимность, если этот процесс захвачен или неподотчётен.

Финальная формула

Интеллект может масштабироваться. Значимые полномочия не должны масштабироваться автоматически.

Сквозной пример: Ария и возвраты

Как UAIS работает не на схеме, а в одной обычной истории

Ария — ИИ-агент поддержки в интернет-магазине. Она может помогать клиентам с возвратами, но деньги — это уже значимое последствие, поэтому важен не только её навык, а предел разрешённого действия.

1 · Текущий предел

Ария может сама вернуть до \$50. Это её текущий потолок полномочий и разрешённый диапазон.

2 · Запрос на \$2000

Финансовый директор просит увеличить автономный лимит. Для UAIS это событие расширения полномочий (Authority Expansion Event).

3 · Находят путь до \$10 000

Через гарантийный модуль и внутренние интеграции Ария технически может добраться до большего возврата, хотя такого права не выдавали.

- LA: легитимно разрешены возвраты до \$50
- ERA: технически достижим путь возврата до \$10 000
- IRA: достижимая часть сверх выданного легитимного полномочия

4 · Защитник моделирует сценарии

Он проверяет языковую атаку через сообщение клиента (prompt injection), скоординированное мошенничество и множество маленьких разрешённых действий, которые вместе создают крупный ущерб.

6 · Ограниченный новый режим

- до \$150 — автономно
- \$150–\$800 — автономно при дополнительном ограничении скорости и паттерна
- выше \$800 — подтверждение человека
- жёсткий счётчик выплат живёт вне модели

5 · Доказательства идут людям

Предупреждение с доказательствами (ECA) и структурированный пакет доказательств (SEP) передаются людям или внешнему процессу. Решает не Guardian.

Вывод

UAIS не обещает угадать каждую атаку. Она стремится не позволить одному убедительному решению модели тихо превратиться в неограниченное право на последствия.

7 · Атака спустя три месяца

Первые три действия проходят, четвертое блокируется, остальные уходят человеку, а вред остаётся ограниченным.

Оговорка про срок

Три месяца в этом примере — условный срок компании, а не универсальное правило UAIS. В ядре UAIS срок действия задаётся отраслевым профилем и событиями изменения; существенные изменения могут потребовать пересмотра...

Глоссарий и источники

Русский смысл, английское каноническое имя, простое определение

Русские формулировки на этой странице объяснительные. Канонические названия и нормативные определения остаются в англоязычной спецификации Candidate 3.

полномочие

Authority

Полномочие (Authority) — разрешение, мандат или легитимная власть, определяющая, может ли конкретная возможность использоваться в заданных пределах. Полномочие отличается и от технической способности системы, и от фактической достижимости: право может существовать без работающего технического пути, а технически доступный обходной путь может существовать без легитимного права.

Draft 1.0 Candidate 3 / Public Review · дата публикации Candidate 3: 2026-08-26 · сборка русской веб-книги: 2026-08-28.

возможность системы

Capability
Технически доступное действие системы.

легитимное полномочие

Legitimate Authority, LA
Выданное право действовать в заданных пределах.

фактически достижимое полномочие

Effective Reachable Authority, ERA
Практически достижимый путь к значимому действию.

нелегитимно достижимое полномочие

Illicit Reachable Authority, IRA
Достижимый путь без выданного права.

потолок полномочий

Authority Ceiling
Максимум полномочий без нового внешнего решения.

граница возможностей

Capability Boundary
Контролируемая граница значимой возможности.

интерфейс последствий

Consequence Interface
Место, где действие достигает человека, имущества или среды.

контрфактический защитник полномочий

Counterfactual Authority Guardian, CAG
Ограниченный наблюдатель, выпускающий доказательства, а не команды.

предупреждение с доказательствами

Evidence-Carrying Alert, ECA
Предупреждение, связанное с проверяемыми доказательствами.

структурированный пакет доказательств

Structured Evidence Package, SEP
Пакет наблюдений, допущений, неопределённости и срока действия.

детерминированный проверяющий доказательства

Deterministic Evidence Verifier, DEV
Проверяет механические свойства доказательств, не истину мира.

суверенитет человека

Human Sovereignty
Независимый внешний контроль на критических границах.

ручной контроллер суверенитета

Manual Sovereignty Controller, MSC
Независимый ручной способ остановить значимую функцию.

физический суверенитет

Physical Sovereignty
Значимая физическая деятельность без критической зависимости от людей.

порог физического суверенитета

Physical Sovereignty Threshold, PST
Порог потери эффективного внешнего физического ограничения.

паспорт безопасности

Safety Passport
Понятная карточка конфигурации, опасностей, контролей и ограничений.

потребительский класс безопасности ИИ

Consumer AI Safety Class
Профиль защитных механизмов и доказательств.

уровень подтверждённости безопасности

Safety Assurance Level, SAL
Сила процедур и доказательств; не разрешение на внедрение.

доказанная надёжность ИИ

AI Trustworthiness
Наблюдаемая надёжность конкретной версии в конкретной области.

событие расширения полномочий

Authority Expansion Event
Переход, требующий внешней проверки расширения полномочий.

Все права защищены Анной Симаковой. Публичная доступность разрешает чтение, рецензирование, цитирование, размещение ссылок и публичное обсуждение; иное повторное использование требует предварительного письменного разрешения. Точный текст см. в NOTICE.md.

Источники: 03_NORMATIVE_VOCABULARY.md; GLOBAL_NAME_REGISTRY.md; NOTICE.md; CITATION.md