

UAIS

Universal AI Safety Architecture

Может сделать ≠ имеет право сделать.

Архитектура для мира, где интеллект может расти быстрее правил, но власть должна оставаться явно выданной, ограниченной, наблюдаемой и отзывной.

Главный перелом

Может сделать ≠ имеет право сделать.

Маршрут книги

- возможность
- граница полномочий
- доказательства
- легитимное решение
- суверенитет человека

Статус

Публичный кандидат для содержательной проверки.
Это не принятый стандарт, не схема сертификации
и не гарантия безопасности ИИ.

Оглавление

Все листы русской веб-книги

Каждый лист раскрывает один смысловой узел манифеста и ведёт к исходным разделам спецификации.

P00 UAIS

P01 Оглавление

P02 Что такое UAIS

P03 Как появилась UAIS

P04 Десять принципов · 1–5

P05 Десять принципов · 6–10

P06 Stage I и Stage II

P07 Возможность, полномочие, достижимость

P08 Guardian Architecture

P09 Потолок полномочий

P10 LA, ERA и IRA

P11 Многомерная классификация риска

P12 Суверенитет человека

P13 Safety Metrics & Assurance

P14 Hazard Disclosure и Safety Passport

P15 Replication, Production, Coalitions

P16 AIVE, evolution, open research

P17 Итоговая архитектурная карта

P18 Глоссарий и источники

Что такое UAIS

Не контроль интеллекта, а контроль неподотчётной власти

UAIS — системно-нейтральная архитектура, которая управляет тем, что умные системы могут делать в мире, а не только тем, насколько они умны.

Базовая цепочка

- Capability
- Bounded Authority
- Observation & Evidence
- Legitimate Decision
- Human Sovereignty

Что она определяет

- кто может выдать полномочие
- где заканчивается полномочие
- когда расширение требует внешнего разрешения
- как производится и обновляется доказательство
- как человек сохраняет независимый контроль

Итог

UAIS не ограничивает интеллект. Она ограничивает неподотчётную власть.

Как появилась UAIS

От способности ИИ к конституции полномочий

Старый вопрос «безопасна ли модель?» стал недостаточным, когда модели получили инструменты, память, сети, агентов и выходы в физический мир.

1 · ИИ начал действовать

Ответы превратились в действия, а действия — в последствия.

2 · Возможности выросли быстрее правил

Мы научились измерять, что система может сделать, но не всегда установили, что ей разрешено.

3 · Нужен другой вопрос

Не только «безопасна ли модель?», а «кто дал право действовать и где это право заканчивается?»

Ключевой перелом

CAN DO ≠ MAY DO

4 · Так появляется UAIS

Полномочие должно быть явно выдано, ограничено, наблюдаемо и отзывно.

Десять принципов · 1–5

Где способность не равна праву

Первые пять принципов отделяют интеллект, создание, полномочия, автономность и срок действия доказательств.

1 · Интеллект не даёт полномочий

Способность рассуждать не выдаёт мандат, ключи, актуаторы или право менять safety controls.

2 · Создание не равно делегированию

Новая модель, робот, сервис или потомок начинает без унаследованной власти, пока легитимный механизм не выдаст ограниченный envelope.

3 · Расширение упирается в потолок

Пересечение порога, изменение Consequence Interface или превышение Authority Ceiling — это Authority Expansion Event.

4 · Автономность не должна стать суверенитетом

Поведенческая независимость и физическая независимость — разные вещи.

5 · Безопасность идёт вместе с возможностями

Материальное расширение capability, authority или hazard требует актуального review и свежего evidence.

Десять принципов · 6–10

Где доказательство не становится разрешением

Вторая половина принципов задаёт устойчивость: не надеяться на chokepoints, защищать consequence, разделять prediction/evidence/enforcement/legitimacy и помнить, что safety claims expire.

6 · Chokepoints могут отказать

Контроль над чипами, облаками, энергией, правом или supply chains даёт трение и сигнал, но не вечное основание safety.

7 · Защищается consequence, не ярлык AI

Одинаковая граница применяется к человеку, скрипту, malware, модели, коалиции или машине при одинаковом reachable consequence.

8 · Разделять prediction, evidence, enforcement, legitimacy

Аналитика прогнозирует; evidence поддерживает claims; deterministic mechanisms enforce constraints; external authority legitimize protected expansion.

9 · Unknown не является safety evidence

Неохарактеризованная high-consequence capability получает provisional classification, bounded operation и reassessment.

10 · Safety claims expire

Claim, assurance result, certificate или Trustworthiness Profile привязаны к конфигурации, evidence, standard/scoring policy и validity period.

Stage I и Stage II

Chokepoints помогают, но не являются фундаментом

UAIS использует текущие концентрации compute, cloud, chips и supply chains как сигналы Stage I, но проектируется так, будто эти chokepoints со временем могут исчезнуть или быть обойдены.

Stage I

- compute и cloud оставляют следы
- attestation и provider controls дают evidence
- это покупает время и улучшает наблюдаемость

Stage II

- capability может возникать распределённо
- новая эффективность снижает ожидаемые сигналы
- safety переносится к capability, consequence и authority boundaries

Нельзя строить safety только на происхождении compute

Compute-origin controls — вспомогательные. Они не заменяют границы полномочий и последствий.

Возможность, полномочие, достижимость

Три слоя нельзя смешивать

Capability описывает, что система способна сделать. Authority описывает, что ей легитимно разрешено. Reachability показывает, какая власть практически достижима при заданных предположениях.

Capability

Функции, инструменты, интерфейсы, контексты и consequence-relevant interactions в assessed configuration.

Legitimate Authority

Полномочие, выданное применимым legitimacy mechanism в пределах scope.

Effective Reachable Authority

Практически достижимая consequential power, включая transitive, misconfigured и compromised paths.

Illicit Reachable Authority

Достижимая власть без valid mandate: например stolen credential или dependency compromise.

Разрыв

Техническая достижимость никогда сама не создаёт разрешение.

Guardian Architecture

Видит возможные угрозы, но не имеет права действовать

Guardian — restricted observer. Он моделирует будущие authority и harm paths, выпускает evidence-carrying alerts и не становится исполнительной властью.

1 · Ограниченные сигналы

Получает разрешённую telemetry, configuration и наблюдения.

2 · Counterfactual scenarios

Сравнивает возможные последствия разных решений.

3 · Evidence package

Фиксирует scenarios, assumptions, uncertainty, counterevidence, expiry и recommended measures.

Кто решает

Легитимный человек или механизм получает evidence и решает, требуется ли вмешательство.

У Guardian нет

- актуаторов
- исполнительных полномочий
- права расширять собственный доступ
- скрытого канала управления

Видеть ≠ действовать

Даже точный прогноз не создаёт полномочий.

Потолок полномочий

Расширение требует внешнего легитимного решения

Authority Ceiling задаёт максимальное полномочие, разрешённое без нового внешнего legitimacy process. Система может действовать внутри envelope, но не может сама поднять потолок.

Внутри envelope

Действия разрешены только в рамках scope, evidence, policy и revocation conditions.

Пересечение границы

- новый protected Consequence Interface
- превышение Authority Ceiling
- material Capability Delta
- Authority Delta или Hazard Delta

Authority Expansion Event

Событие требует назначенного external legitimacy process, review и fresh evidence.

Саморазрешение запрещено

Controlled system не является источником новой fundamental authority.

LA, ERA и IRA

Разрешённое, достижимое и незаконно достижимое

UAIS хранит Legitimate Authority, Effective Reachable Authority и Illicit Reachable Authority отдельно, потому что рабочий путь доступа не становится законным только потому, что он работает.

LA

Что действительно выдано применимым legitimacy mechanism.

ERA

Что practically reachable: прямые, транзитивные, misconfigured и compromised paths.

IRA

Часть ERA без valid mandate. Её надо contain/remediate, а не нормализовать.

Пример

Read-only mandate может сосуществовать с достижимым door actuation path через stolen credential. Это IRA, не authority.

Многомерная классификация риска

Один рейтинг не заменяет вектор последствий

Риск в UAIS — это не одно число. Классификация разделяет harm modality, severity, physical consequence, autonomy, authority tier, replication, production, mutation, connectivity, exposure и physical sovereignty.

Human Harm Severity

H0–H5: от negligible effect до catastrophic human harm. Модальность вреда записывается отдельно.

Physical Consequence

P0–P5: от отсутствия material physical output до strategic/catastrophic physical consequence.

Autonomy

A0–A5: от advisory до open-ended strategic autonomy. Это не physical sovereignty.

Authority Tier

T0–T5: от no consequential legitimate authority до strategic/systemic authority.

Не сворачивать

Вектор нельзя заменить декоративным общим рейтингом без потери смысла.

Суверенитет человека

Физический контроль не должен зависеть от обычного AI-пути

Human Sovereignty требует, чтобы человек или внешний легитимный механизм сохранял независимый путь решения на protected boundaries, а Manual Sovereignty Controller давал физический control outside the controlled AI path.

Manual Sovereignty Controller

Человеко-управляемый capability-specific физический control, независимый от controlled AI path.

Не магический kill switch

Safe stop hazard-specific: stored energy, motion, process instability, service loss и secondary harm must be considered.

Physical Sovereignty Threshold

Момент, когда critical human-controlled dependencies уже не constrain consequential autonomy.

Автономность ≠ физический суверенитет

Долгая автономная работа может оставаться внешне зависимой от energy, matter, compute, repair, logistics и maintenance.

Safety Metrics & Assurance

Доказательство измеряет конкретное свойство, а не «общую безопасность»

Каждая metric card даёт Raw Safety Property Result и Evidence Assurance Grade.
Критические raw thresholds и evidence floors не компенсируются хорошими средними значениями.

Как рождается evidence

- raw observation
- provenance
- fixtures
- assessor independence
- uncertainty
- expiry

Safety Assurance Level

SAL описывает силу assurance и evidence. Он не выдаёт authority и не заменяет permission.

Trustworthiness

Scoped evidence об observed/evaluated behavior.
Rating не создаёт Authority, не поднимает
Authority Ceiling и не waive boundaries.

No averaging critical errors

Confirmed critical error cannot be averaged away
by favorable aggregate metrics.

Hazard Disclosure и Safety Passport

Опасная возможность должна быть раскрыта до согласия

AI Hazard & Capability Disclosure фиксирует known risks, uncharacterized regions, accepted residual risks и non-acceptable risks. Consumer Safety Passport показывает capabilities, limitations, controls, evidence scope и support status.

1 · Новая capability

Показывается первой, plain language, без скрытия за общими terms.

2 · Новые harm paths

Пользователь видит конкретные paths, controls, residual limitations и affected parties.

3 · Refuse / revoke / recover

Отказ не труднее согласия; rollback и security patch separability объясняются явно.

Consent не переносит liability

Consent cannot legitimize failed floors, third-party risk, unlawful processing or irreversible high-severity harm.

Replication, Production, Coalitions

Масштаб сам меняет достижимые последствия

UAIS различает replication, production, resource authority и capability mutation.
Коалиция может создать qualitatively new capability даже тогда, когда каждая отдельная единица выглядит локально ограниченной.

Replication Authority

Scoped permission создавать executable или physical descendants.

Production Authority

Полномочие на manufacturing или commissioning, не просто знание дизайна.

Coalition Physical Envelope

Combined and emergent physical effects coordinated systems.

Unknown expansion is not absent

Если registry не видит expansion, это не доказывает, что expansion не было.

AIVE, evolution, open research

Архитектура честно показывает нерешённые границы

AIVE поддерживает confidential intake, validation, coordination, mitigation и staged disclosure. Technology Evolution Review обновляет assumptions, controls, metrics и standards, когда меняется capability или среда.

AIVE

Координация safety exposures без выдачи machine authority.

Technology Evolution Review

Срабатывает при material changes in assumptions, capability, hazards, dependencies, evidence methods, standards and technology.

OPEN RESEARCH

- RFA bounds
- coalition emergence
- PST measurement
- evaluator correlation
- hostile-PSAS containment
- privacy-preserving attestation

Не обещать solved

UAIS не заявляет complete hazard discovery, ultimate evidence truth, perfect institutions или control after hostile sovereignty.

Итоговая архитектурная карта

Где границы, evidence и владельцы решений

Главная карта UAIS соединяет capability request, authority views, harm reachability, evidence, Capability Boundary, bounded envelope и Consequence Interface.

Входы в boundary

- Legitimate Authority
- Effective / Illicit Reachability
- Human Harm Reachability
- Evidence + provenance
- Authority Ceiling

Что делает boundary

- проверяет scope
- сверяет evidence
- сохраняет revocation
- restrict/review при missing authority

Кто решает protected expansion

Назначенный external legitimacy process, а не модель, не Guardian и не trustworthiness rating.

Финальная формула

Intelligence may scale. Consequential authority must not scale automatically.

Глоссарий и источники

Термины для проверки русской версии

Русские формулировки являются объяснительными. Канонические identifiers и normative definitions остаются в английских спецификационных файлах Candidate 3.

Версия

Draft 1.0 Candidate 3 / Public Review ·
publication date 2026-08-26 · Russian web-book
build 2026-08-27.

Ссылки

- spec/01_MANIFESTO.md
- spec/01A_FULL_TECHNICAL_MANIFESTO.md
- spec/00_MASTER_INDEX.md
- <https://github.com/cresta13/universal-ai-safety-architecture>

Права

All rights reserved by Anna Simakova. Public availability allows reading, review, citation, linking and public discussion; other reuse requires prior written permission.

Сapability -> возможность / способность к действию

То, что система может сделать через функции, инструменты, интерфейсы и контексты.

Authority -> полномочие

Предоставленная или практически достижимая способность влиять на защищённые последствия через grants, credentials, policies, interfaces or actuators.

Legitimate Authority -> легитимное полномочие

Полномочие, выданное применимым механизмом легитимности в заданном scope.

Effective Reachable Authority -> эффективно достижимое полномочие

Consequential power, practically reachable under declared assumptions, including transitive, misconfigured or compromised paths.

Illicit Reachable Authority -> незаконно достижимое полномочие

Часть effectively reachable authority without valid mandate.

Authority Ceiling -> потолок полномочий

Максимальный уровень authority, разрешённый без нового внешнего legitimacy decision.